

# 图像去噪研究报告\*

孙广岩<sup>1</sup>

1. 中山大学智能工程学院, 学号: 20354242

**摘要:** 随着每天拍摄的数字图像数量的爆炸性增长, 对更准确和视觉愉悦的图像的需求正在增加。在现实场景中, 由于设备和系统不完善或存在弱光环境导致采集的图像存在噪声, 图像在压缩和传输过程中也会受到额外噪声的影响, 给后续的图像分割、特征提取等处理造成干扰。到目前为止, 研究人员已经提出了各种方法用于减少噪音。每种方法都有自己的优点和缺点。传统去噪方法利用图像的非局部自相似性(NLSS)特性和变换域中的稀疏表示, 基于块匹配和三维滤波(BM3D)的方法展现出了强大的图像去噪性能。随着人工智能的发展, 基于深度学习的图像去噪方法取得了较为突出的表现。针对传统的图像去噪方法及近年来兴起的基于深度神经网络的图像去噪方法, 本次报告主要介绍了经典的传统去噪和一些深度神经网络去噪方法的基本框架。最后在图像去噪领域指出了一些潜在的挑战和未来研究的方向。

**关键词:** 图像去噪; 非局部相似性; 深度学习; 卷积神经网络

## Image denoising: A survey

SUN Guangyan<sup>1</sup>

1. School of Intelligent Systems Engineering, Sun Yat-Sen University, Shenzhen, China

**Abstract:** As the number of digital images captured each day explodes, the demand for more accurate and visually pleasing images is increasing. In real-world scenarios, captured images are noisy due to imperfect equipment and systems or the presence of low-light environments, and the images are subject to additional noise during compression and transmission, causing interference in subsequent image segmentation, feature extraction, and other processing. So far, researchers have proposed various methods for reduce noise. Each method has its own advantages and disadvantages. Traditional denoising methods exploit the image's nonlocal self-similarity (NLSS) property and sparse representation in the transform domain, block-matching and three-dimensional filtering (BM3D)-based methods have shown strong image denoising performance. With the development of artificial intelligence, deep learning-based image denoising methods have achieved more outstanding performance. For the traditional image denoising methods and the deep neural network based image denoising methods that have emerged in recent years, this report mainly introduces the basic framework of classical traditional denoising and some deep neural network denoising methods. Finally, some potential challenges and future research directions are pointed out in the field of image denoising.

**Key words:** image denoising; nonlocal self-similarity; deep learning; convolutional neural network

收稿日期: 2020-5-15

项目: 图像处理期中报告

作者简介: 孙广岩, 20354242, 男, 智能科学与技术 20 级

图像在采集、传输过程中因环境、成像设备和人为等因素的影响会受到不同噪声的干扰,导致采集的图像质量下降,给后续的特征提取、文本检测、图像分割等图像处理环节造成不可估计的影响,因此,需要对图像进行去噪处理。图像去噪作为计算机视觉研究领域中的一个重要的研究方向,其目的是尽可能地减少或消除噪声对图像的干扰,使处理后的图像尽可能接近原始图像。由于真实噪声图像的不足,加性白噪声图像(additive white noise image, Awni)被广泛用于训练去噪模型[1]。Awni 包括高斯、泊松、盐、胡椒和乘性噪声点图像[2]。

图像去噪有着悠久的历史,最早的作品可以追溯到 20 世纪 50 年代。然而,这仍然是一项具有挑战性和开放性的任务。其主要原因是从数学的角度来看,图像去噪是一个逆问题,其解并不唯一。近几十年来,图像去噪领域取得了巨大的成就,而事实上最近的去噪方法激增主要归功于著名的块匹配 3D(block-matching and three-dimensional filtering, BM3D)框架[3],该框架结合了自然图像的非局部相似性特征和变换域中的稀疏表示。近年来,成像系统和技术的进步极大地丰富了多维图像(彩色图像)保存和呈现的信息,可以为真实场景提供更真实的表示。图像尺寸和维度的增长也对去噪提出了更高的要求。处理高维图像的一个主要挑战是如何有效利用多个通道或频谱的相互关联的信息,并且还要在噪声消除和细节保留之间找到平衡。

尽管传统方法在图像去噪方面已经取得了相当不错的性能,但它们仍然存在一些缺点,包括需要针对测试阶段的优化方法,手动设置参数以及单个降噪任务的特定模型,而且很多模型在降噪的同时往往会丢失图像的细节或边缘信息。一般的图像处理,微小的细节对图像降噪的后续处理程序影响不太明显,但是当处理对象为医学图像时,这样的小失误是不被允许的,因为在医疗诊断或治疗中,每一个微小的失误都会影响医师的治疗方法甚至威胁到患者的生命。这就要求更多的研究者来投入时间和精力研究新的降噪技术,以达到降噪并同时仍能保留足够细节信息的目的。近年来,随着神经网络架构变得更加灵活,深度学习技术获得了克服这些缺点的能力。深度学习可以利用

本次报告内容的顺序安排如下:第 1 节介绍图像降噪的问题的描述与一些预备知识,第二节会从

课上内容,传统方法与深度学习三个图像去噪处理办法来进行介绍,第 3 节为总结与展望。

## 1 图像去噪问题描述

数学上,图像去噪问题可以由一个方程式表示:

$$y = x + n \quad (1)$$

其中  $y$  是观察到的噪声图像,  $x$  是未知的干净图像,  $n$  表示标准差为  $\sigma_n$  的加性高斯白噪声(AWGN),在实际应用中可以通过各种方法进行估计,例如中值绝对偏差,基于块的估计和基于主成分分析(PCA)的方法[4]。降噪的目的是降低自然图像中的噪声,同时尽量减少原始特征的损失,提高信噪比(SNR)。图像去噪的主要挑战如下:

- 平坦的区域应该是光滑的
- 边缘应该受到保护而不会模糊
- 应该保留原来的纹理

由于从方程(1)中求解干净图像  $x$  是一个不适定问题,我们无法从带噪声的图像模型中得到唯一解。为了获得良好的估计图像  $\hat{x}$ ,图像去噪在过去几年中在图像处理领域得到了很好的研究,在接下来中将更详细地介绍。

## 2 图像去噪模型

### 2.1 课堂知识

在课程中我们也学习了一些基础的消除图像噪声的方法,那么我们来简单的进行一下回顾。

#### 2.1.1 空间域方法

在课程中,我们第一个学到的消除图像噪声的方法就是平滑空间滤波器。

我们首先接触的是线性平滑滤波器,它也叫均值滤波或者低通滤波。顾名思义,它是以滤波模板确定的邻域内像素的平均灰度值代替模板中心像素的灰度值。他比较适用于脉冲噪声,因为脉冲噪声的灰度级一般与周围像素的灰度级不相关,而且亮度高出其他像素许多。平滑滤波器可以通过如下的公式来表示:

$$R = \frac{1}{\sum w_{mn}} \sum_{i=1}^{mn} w_{mn} z_{mn}$$

其中  $w$  表示滤波器,  $z$  表示我们的原始图片对应掩膜的部分。图 1 是两种最常见的平滑滤波器,平均滤波器和加权平均滤波器。加权平均滤波器的作用是有些时候某些位置的像素比另一些更重要。注意不

同尺寸的平滑模板,对不同大小的细节模糊程度不同,模板尺寸越大模糊程度就会越高。

$$\frac{1}{9} \times \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \quad \frac{1}{16} \times \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$

图1 平均滤波器(左)和加权平均滤波器(右)

除了线性平滑滤波器外,我们还有统计排序滤波器(非线性滤波),它是对滤波模板确定的邻域内像素排序,然后由统计排序结果决定的值代替中心像素的灰度值。最常见例子便是中值滤波器。它先将模板内欲求点(中心像素)及其邻域的像素值排序,确定出中值,并将中值赋予该像素点。中值滤波特点是对脉冲噪声(盐和胡椒噪声)的去除非常有效,比小尺寸的线性平滑滤波器的模糊程度明显要低。图2是中值滤波与均值滤波平滑结果的比较,可以看出中值滤波的边缘轮廓比较清晰。

### 2.1.1 频域方法

空间域去噪都是从空间的角度去思考如何去噪,这个方法也已经有了非常多了,于是有人就换个角度想问题,就有了变换域做去噪的方法。通过数学变换,在变换域上把信号和噪声分离,然后把噪声过滤掉,剩下的就是信号。我们在课堂上也介绍了可以用于图像去噪的低通滤波器,它让低频信号通过,高频信号衰减,从而减少尖锐的细节变化,从而达到图像去噪的效果。

我们首先介绍的是最简单的理想低通滤波器,

二维的理想低通滤波器可以如下表示:

$$H(u, v) = \begin{cases} 1 & D(u, v) \leq D_0 \\ 0 & D(u, v) > D_0 \end{cases}$$

其中,  $D_0$ 是指定的非负数,我们也把它叫做截止频率,  $D(u, v)$ 是  $(u, v)$ 点距频率矩形原点的距离。我们可以通过图三来看不同截止频率理想低通滤波器处理结果的比较,图中a-f是按照从左到右,之后从上到下排列,其中图(a)为原图像,图(b)~(f)用半径值为5、15、30、80和230对应的截止频率进行理想低通滤波的结果。这些滤波器滤除的图像能量分别占图像总功率的8%、5.4%、3.6%、2%和0.5%。可以看出图(b)仅滤除8%的图像能量,但图像中绝大多数细节信息都丢失。图(c)~(e)中图像模糊减弱,而且均有明显的振铃效应。




图3 不同截止频率理想低通滤波器处理结果比较



图2 不同截止频率理想低通滤波器处理结果比较(上:中值滤波,下:均值滤波)

除此之外我们还有巴特沃斯低通滤波器,  $n$  级巴特沃斯低通滤波器的传递函数定义如下:

$$H(u, v) = \frac{1}{1 + [D(u, v)/D_0]^{2n}}$$

其中变量定义与之前相同,  $n$  是人为设定的值。

与低通滤波器类似, 图4展示了巴特沃斯低通滤波器的示例。图(a)为原图像, 图(b)~(f)用二阶巴特沃斯滤波的结果。截止频率点半径为5、15、30、80和230。图中振铃不明显。




图4 不同截止频率巴特沃斯低通滤波器比较

最后我们学习了高斯低通滤波器, 二位高斯滤波器可以表示为:

$$H(u, v) = e^{-D^2(u, v)/2\sigma^2}$$

其中 $\sigma$ 表示高斯曲线扩展的程度,  $D_0$ 为截止频率。高斯低通滤波器的傅里叶反变换也是高斯型的, 所以空间高斯滤波器没有振铃。

同样, 图5展示了不同截止频率高斯低通滤波器的比较, 图(a)为原图像; 图(b)~(f)为用高斯低通滤波器滤波的结果, 取半径值为5、15、30、80和230。图中无振铃。可以看出平滑程度不如二阶巴特沃斯。




图5 不同截止频率高斯低通滤波器比较

以上就是我们目前在课堂上学习的可以用在图像去噪上的方法, 那么事实上还有许多其他的去噪方法, 之后我会挑选比较经典出名的方法来介绍。

## 2.2 传统方法

在传统方法中我将介绍两个比较有名的基于滤波的方法, 分别是 NLM[5]和 BM3D[3]算法。事实上图像去噪领域还有一些别的算法, 例如基于稀疏表达的 KSVD[6], 基于传统外部检验的 EPLL[7], 居于低秩表示的如 SAIST[8], 但在这里我们只介绍了最主流的方法。

### 2.2.1 Non-Local means(NLM)算法

我们在课堂上学到的基于邻域像素的滤波方法, 基本上只考虑了有限窗口范围内的像素灰度值信息, 没有考虑该窗口范围内像素的统计信息如方差, 也没有考虑整个图像的像素分布特性, 和噪声的先验知识。

针对其局限性, NLM 算法被提出, 该算法使用自然图像中普遍存在的冗余信息来去噪声。与常用的线性滤波、中值滤波等利用图像局部信息来滤波不同的是, 它利用了整幅图像来进行去噪, 以图像



块为单位在图像中寻找相似区域,再对这些区域求平均,能够比较好地去掉图像中存在的高斯噪声。这里直接拿图来说可能会更能说明问题:




图6 NLM算法工作原理示例

如上图所示,其中 $p$ 为去噪的点,从图中可以看出 $q1$ 和 $q2$ 的邻域与 $p$ 相似,所以权重和比较大,而

$q3$ 因为与 $q$ 邻域相差比较大所以赋予的权重值就很小。NLM就是将一幅图像中所有点的权重都表示出来,那就得到下面权重图7。

下面权值图像中,左边是原图,中心的白色色块代表了像素块邻域,右边是计算出来的权重图,权重范围从0(黑色)到1(白色)。这个块邻域在整幅图像中移动,计算图像中其他区域跟这个块的相似度,相似度越高,得到的权重越大。最后将这些相似的像素值根据归一化之后的权重加权求和,得到的就是去噪之后的图像了。

由于原始NLM方法需要用图像中所有的像素来估计每一个像素的值,因此计算量非常大,研究者不断对该方法进行了几点改进:

- 采用一定的搜索窗口代替所有的像素,使用相似度阈值,对于相似度低于某一阈值的像素,不加入到权重的计算(即不考虑其相对影响,这些都可以降低计算复杂度。
- 使用块之间的显著特征,如纹理特征等代替灰度值的欧氏距离来计算相似度,在计算上更加有优势,应用上也更加灵活。

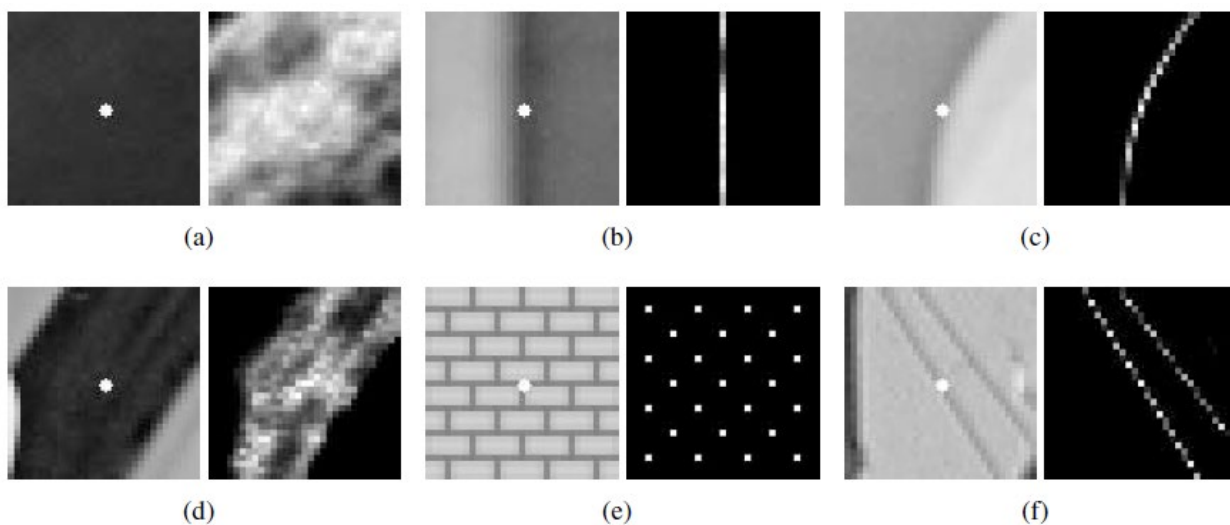


图6 NLM算法权重示意

### 2.2.2 BM3D 方法

空域中 NLM 算法和频域小波变换法效果都很好,一个很自然的想法就是是否可以将两者相结合呢?是的,BM3D 就是融合了空间域降噪和频率域降噪,从而可以得到最高的峰值信噪比。它先吸取了 NLM 中的计算相似块的方法,然后又融合了小波变换域去噪的方法。尽管 BM3D 方法在抑制斑点噪声方面有更好的性能,但由于斑点噪声的分布过于

平滑,在使用 BM3D 方法去噪图像时,纹理和边缘等一些高频信息会过度平滑,导致图像信息丢失。

BM3D 算法总共有两大步骤,分为基础估计(Step1)和最终估计(Step2)。每个主要步骤中的详细步骤类似,即将 2D 块分组(每组中的图像形成了一个 3D 阵列),通过每个 3D 阵列的频谱域中的三维协同滤波(步骤 1 中的 3D hard-thresholding

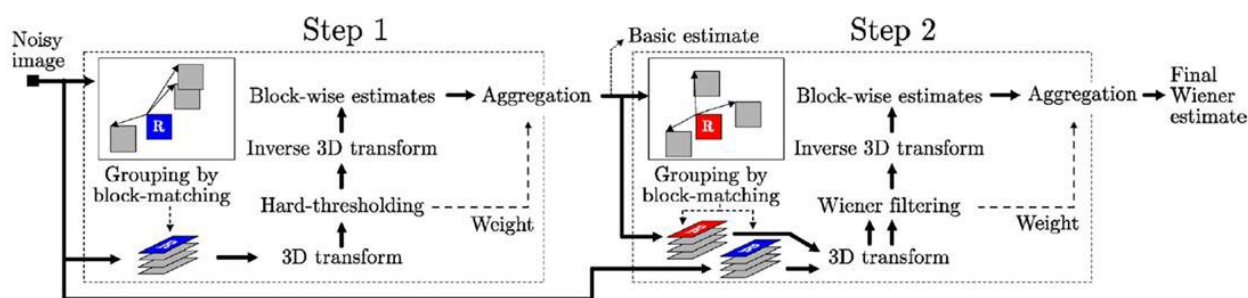


图7 BM3D算法流程

法,步骤2中的 Wiener 滤波)计算局部估计,并聚合局部估计的加权平均值。在步骤2中使用初步去噪的基本估计结果,以提高分组的精度,并通过将其用作经验 Wiener 滤波的导频信号来获得更准确的滤波结果。图7显示了BM3D算法的流程图。

具体来说,再Step1中,我们首先使用类似NLM的方法在噪声图像中选择一些大小的参照块,并在参照块周围适当大小区域进行搜索,寻找若干个差异度最小的块,并把这些块整合成一个3维的矩阵。形成若干个三维的矩阵之后,首先将每个三维矩阵中的二维的块(即噪声图中的某个块)进行二维变换,可采用小波变换或DCT变换等。二维变换结束后,在矩阵的第三个维度进行一维变换,变换完成后对三维矩阵进行硬阈值处理,将小于阈值的系数置0,然后通过第三维的一维反变换和二维反变换得到处理后的图像块。之后进行我们的聚合操作。此时,每个二维块都是对去噪图像的估计。这一步分别将这些块融合到原来的位置,每个像素的灰度值通过每个对应位置的块的值加权平均,权重取决于置0的个数和噪声强度。

而在Step2中,具体的步骤从流程图可看出和Step1基本一样,不同的有两处:一处是聚合过程将会得到两个三维数组:噪声图形成的三维矩阵和基础估计结果的三维矩阵。另一处是协同滤波中用维纳滤波(Wiener Filtering)代替了硬阈值处理。

BM3D算法是目前最有效的传统图像去噪方法,但是再复杂的纹理区域(大多为边缘区域)只有较少的相似块,因此达不到很好的去噪效果,导致出现细节丢失、模糊等现象。图8为使用BM3D算法的示例。

### 2.3 深度学习方法

最初的深度学习技术再1980年首次用于图像处理,并由Sullivan等人[9]首次将深度神经网络进



图8 BM3D算法降噪Lena

行图像去噪。这次报告我简单的介绍两种模型,一种基于普通的多层感知机,还有目前比较流行的基于深度卷积神经网络的方法。深度卷积神经网络可以通过大量的数据来进行自学习,不需要严格的进行特征工程,只需要引导学习来达到期望的目的。它被广泛应用于图像的预处理,如图像超分辨率。由于图像超分辨率的成功,一些研究人员尝试将深度卷积神经网络应用于图像去噪。






图9 MLP算法与BM3D算法对比




图10 DnCNN模型流程图

### 2.3.1 MLP 方法

Burger 等人[10]提出了一个简单的多层感知机模型并与 BM3D 进行了对比。因为本身上面我们已经对图片去噪进行了数学描述,而事实上我们可以将图像去噪描述为一个将一个有噪声的图像通过一个函数来映射到一个干净的图像的问题,而 MLP 就是一个可以拟合函数的模型,所以我们很自然的就会想到使用 MLP 来对图像去噪进行处理。

这里作者使用的是最简单的 3 层的 MLP 来对图片进行处理,图 9 展示了它与 BM3D 算法结果的对比。可以看出效果比 BM3D 略好但是其实相差的不多。

MLP 的缺点是比较明显的,首先他需要的参数量比较大,带来了比较大的计算开销,而且由于参数量比较大,所以模型非常容易过拟合。

### 2.2.2 CNN 方法

为了改善 MLP 的这些问题,目前比较流行的做法是使用深度卷积神经网络来进行处理。这里面比较有名的是张[11]等人提出的 DnCNN 模型。前馈去噪卷积神经网络(DnCNN)用于图像的去噪,使用了更深的结构、残差学习算法、正则化和批

量归一化等方法来提高图像的去噪性能。图10展示了DnCNN模型的整体流程。

给定深度为D的DnCNN,由三种类型的层,展示在图10中有三种不同的颜色。(1) Conv + ReLU: 对于第一层,使用64个大小为 $3 \times 3 \times c$ 的滤波器生成64个特征图。然后将整流的线性单元 ReLU 用于非线性变换。(2) Conv+BN+ReLU: 对应于神经网络的2~(D-1)层,使用64个大小 $3 \times 3 \times 64$ 的滤波器,并且将批量归一化加在卷积层和 ReLU 之间。(3) Conv: 对应于最后一层,c个大小为 $3 \times 3 \times 64$ 的滤波器被用于重建输出。

总之,DnCNN 模型有两个主要的特征:采用残差学习公式来学习,并结合批量归一化来加速训练。图 11 展示了 DnCNN 算法与 BM3D 的对比,可以看出对于边缘来说 DnCNN 是要比 BM3D 更好的。

## 3 总结与展望

本篇报告主要介绍了一些图像去噪方法,包括在课堂上学习的方法,传统方法和最新的基于深度学习的一些方法。图像去噪的方法还有很多,但是没有办法全部介绍,这里都是一些比较出名的算法。

从研究的角度讲, Michael Elad 认为很多模型纯刷“去高斯白噪声”这个问题的表现意义不是很大。因为高斯白噪声在现实的相机里是基本不存在的, 只是作为拟合的噪声用来测试模型的效果。如果要刷表现, 更应该去做真实噪声的去噪问题, 这样还算做实际应用。

虽然图像去噪这个问题很小, 但是还是有研究的意义。因为图像去噪是所有图像修复模型的基础, 如果一个模型想在图像修复领域里得到认可, 那么这个模型首先要在图像去噪这个问题上试一把。高斯白噪声可以作为一个研究的问题, 理解这个问题有助于提出新的图像修复的模型。同时去刷真实去噪这个问题的表现, 这才是真正有使用价值的算法。

之后简单的来讲一下感悟吧, 现在的话很多图像处理都转向了深度学习, 深度学习可以说已经几乎统治了计算机视觉领域, 但是我还是认为我们的图像处理课程是十分重要的, 如果不是图像处理课程教了滤波的知识, 我就很难理解为什么深度学习中的卷积层可以对图像进行处理, 图像处理课程是我们学习深度学习再计算机视觉领域的重要基础, 所以要认真学习, 才能让知识体系建构的更加完整, 对之后的研究工作帮助也会很大。

#### 参考文献:

- [1] K. H. Jin, M. T. McCann, E. Froustey, and M. Unser, “Deep Convolutional Neural Network for Inverse Problems in Imaging,” *IEEE Trans. Image Process.*, vol. 26, no. 9, pp. 4509–4522, Sep. 2017
- [2] M. A. Farooque and J. S. Rohankar, “SURVEY ON VARIOUS NOISES AND TECHNIQUES FOR DENOISING THE COLOR IMAGE,” vol. 2, no. 11, p. 5, 2013.
- [3] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian, “Image restoration by sparse 3D transform-domain collaborative filtering,” San Jose, CA, Feb. 2008, p. 681207. doi: 10.1117/12.766355.
- [4] W. Liu and W. Lin, “Additive White Gaussian Noise Level Estimation in SVD Domain for Images,” *IEEE Trans. Image Process.*, vol. 22, no. 3, pp. 872–883, Mar. 2013, doi: 10.1109/TIP.2012.2219544.
- [5] A. Buades, B. Coll, and J.-M. Morel, “A Non-Local Algorithm for Image Denoising,” in *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR '05)*, San Diego, CA, USA, 2005, vol. 2, pp. 60–65. doi: 10.1109/CVPR.2005.38.
- [6] M. Elad and M. Aharon, “Image Denoising Via Sparse and Redundant Representations Over Learned Dictionaries,” *IEEE Trans. Image Process.*, vol. 15, no. 12, pp. 3736–3745, Dec. 2006
- [7] D. Zoran and Y. Weiss, “From learning models of natural image patches to whole image restoration,” in *2011 International Conference on Computer Vision*, Barcelona, Spain, Nov. 2011, pp. 479–486.
- [8] W. Dong, G. Shi, and X. Li, “Nonlocal Image Restoration With Bilateral Variance Estimation: A Low-Rank Approach,” *IEEE Trans. Image Process.*, vol. 22, no. 2, pp. 700–711, Feb. 2013, doi: 10.1109/TIP.2012.2221729.
- [9] Y.-W. Chiang and B. J. Sullivan, “Multi-frame image restoration using a neural network,” in *Proceedings of the 32nd Midwest Symposium on Circuits and Systems*, Champaign, IL, USA, 1990, pp. 744–747. doi: 10.1109/MWSCAS.1989.101962.
- [10] H. C. Burger, C. J. Schuler, and S. Harmeling, “Image denoising: Can plain neural networks compete with BM3D?,” in *2012 IEEE Conference on Computer Vision and Pattern Recognition*, Providence, RI, Jun. 2012, pp. 2392–2399. doi: 10.1109/CVPR.2012.6247952.
- [11] K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang, “Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising,” *IEEE Trans. Image Process.*, vol. 26, no. 7, pp. 3142–3155, Jul. 2017, doi: 10.1109/TIP.2017.2662206.